



Факультет компьютерных наук

Искусственный  
интеллект

Москва  
2025

# Мультимодальное слияние и совместные энкодеры




# План

1. Проблема dual-encoder подхода
2. Стратегии слияния модальностей
  - раннее, позднее, совместное слияние (deep fusion, shortcut fusion и др.)
  - визуальные схемы примеров
3. Кросс-модальное внимание и архитектуры слияния
  - cross-attention: механизм и его роль
  - примеры: VisualGPT, Flamingo, VC-GPT
4. Архитектуры совместных энкодеров и pretraining задачи
  - ViLBERT, LXMERT, VisualBERT, FLAVA, BridgeTower
  - задачи: masked language modeling, image-text matching
5. PrefixLM и Frozen PrefixLM
  - SimVLM, VirTex, Frozen, ClipCap (слайды 5–6)
  - генеративный pretraining с фиксированными энкодерами
6. Дополнительные подходы: без обучения
  - пример MaGiC
7. Обзор моделей в 🤗 Transformers
  - доступные реализации: BLIP, FLAVA, GIT, ViLT, и др.



# Проблема dual-encoder подхода

## 1. Contrastive pre-training




## Ограничения:

- хорошо для retrieval;
- слабо для тонких многозвеньевых рассуждений и VQA;
- нет плотного поэлементного взаимодействия токенов изображения и текста.




# Стратегии слияния модальностей


*раннее слияние - позднее слияние - совместное слияние*




(a) Early Fusion




(b) Late Fusion




(c) Middle Fusion - fusion in one layer




(d) Middle Fusion - deep fusion



(e) Middle Fusion – short-cut fusion




# PrefixLM pre-training strategy



SimVLM and VirTex




# Frozen PrefixLM




Frozen and ClipCap

# Кросс-модальное внимание






# Multi-modal Fusing with Cross Attention




(a) The Vanilla Framework.

VisualGPT, VC-GPT, and Flamingo






# Masked-Language Modeling / Image-Text Matching



pre-training setup include VisualBERT, FLAVA, ViLBERT, LXMERT and BridgeTower


# No Training



$$\text{rr}(x^*) = \begin{array}{|c|c|c|} \hline \text{light green} & \text{medium green} & \text{dark green} \\ \hline \end{array}$$

$$\text{rr}(\hat{y}_i) = \begin{array}{|c|c|c|} \hline \text{dark green} & \text{light green} & \text{very light green} \\ \hline \end{array}$$

$$\text{rr}(\hat{y}_j) = \begin{array}{|c|c|c|} \hline \text{very light green} & \text{dark green} & \text{medium green} \\ \hline \end{array}$$



# Vision-Language Models in 🤗 Transformers

CLIP

FLAVA

GIT

BridgeTower

GroupViT

BLIP

OWL-ViT

CLIPSeg

X-CLIP

VisualBERT

ViLT

LiT (an instance of the  
VisionTextDualEncoder)

TrOCR (an instance of the  
VisionEncoderDecoderModel)

VisionTextDualEncoder

VisionEncoderDecoderModel

